

Primera Implementación Módulo 1

Descripción del dataset:

Dry Bean

Para la investigación se utilizaron siete tipos diferentes de frijoles secos, teniendo en cuenta características como la forma, el tipo y la estructura según la situación del mercado. Se desarrolló un sistema de visión artificial para distinguir siete variedades registradas diferentes de frijoles secos con características similares con el fin de obtener una clasificación uniforme de las semillas. Para el modelo de clasificación, se tomaron imágenes de 13.611 granos de 7 variedades diferentes de frijoles secos registrados con una cámara de alta resolución. Las imágenes de los granos obtenidas mediante un sistema de visión artificial fueron sometidas a etapas de segmentación y extracción de características, y se obtuvieron un total de 16 características: 12 dimensiones y 4 formas.

① Predicción

$$z = W^T x + b, \text{ donde:}$$

$$x \in \mathbb{R}^n, \quad b \in \mathbb{R}^n$$

para n features



$$x = \begin{bmatrix} x_1 \\ \vdots \\ x_n \end{bmatrix}$$

$$W \in M(\mathbb{R}^{n \times K})$$

para n features
y K clases (labels)



$$W = \begin{bmatrix} w_{11} & \dots & w_{1K} \\ \vdots & & \vdots \\ w_{n1} & \dots & w_{nK} \end{bmatrix}$$

entonces $z = [z_1, \dots, z_K]$

② Función de activación

Softmax: es una "normalización"

$$\begin{bmatrix} a_1 \\ \vdots \\ a_k \end{bmatrix} \xrightarrow{\sigma} \begin{bmatrix} b_1 \\ \vdots \\ b_k \end{bmatrix} \quad \text{tq} \quad a_k \in \mathbb{R} \rightarrow b_k \in (0, 1)$$

$$\sigma: \mathbb{R}^k \rightarrow (0, 1)^k \quad \sigma(z)_i = \frac{e^{z_i}}{\sum_{j=1}^n e^{z_j}}$$

e^{z_i} → 1 categoría
suma de las n categorías
para estabilidad numérica: $z'_i = z_i - \max(z_i)$
antes de la exponencial

③ Loss function

Usamos $-y \log(\hat{y})$ con one-hot encoding

$$L = - \sum_{i=0}^n y_i \log(\hat{y}_i)$$

donde y_i es un vector de 0s con un solo 1 en la posición de la categoría a la que corresponde en la instancia i

$$y_i = [0, 0, \dots, 1, \dots, 0]$$

$$\text{entonces } L = -(0 \log \hat{y}_0 + 0 \log \hat{y}_1 + \dots + 1 \log \hat{y}_m + \dots + 0 \log \hat{y}_n)$$

$$L = -\log \hat{y}_m$$

④ Batch

Dividimos el dataset en batches de h instancias

ej $h=100$

$$\Rightarrow X_h \in \mathbb{R}^{h \times n} \rightarrow \text{features}$$

$$\Rightarrow W \in \mathbb{R}^{n \times K} \Rightarrow Z = X_h * W \quad (h \times n)(n \times K)$$

$$\Rightarrow Z \in \mathbb{R}^{h \times K}$$

$$\text{softmax}(Z) = \hat{Y} \in \mathbb{R}^{h \times K}$$

y para calcular su costo se saca un promedio de pérdida

$$L = -\frac{1}{h} \sum_{j=0}^h \left(\sum_{i=0}^K y_{i,j} \log \hat{y}_{i,j} \right)$$

↓
instancias

↓
loss por instancia

$$L = \frac{1}{h} \left(\text{loss inst } 1 + \text{loss inst } 2 + \dots + \text{loss inst } h \right)$$

⑤ Gradient-descent

Ya tenemos $X \in \mathbb{R}^{h \times n}$, $W \in \mathbb{R}^{n \times K}$, $b \in \mathbb{R}^n$, $Z \in \mathbb{R}^{h \times K}$

$$\Rightarrow \text{Softmax}(Z) = \hat{Y} \in \mathbb{R}^{h \times K}$$

$$\Rightarrow L = \ell(\hat{Y}, Y) \in \mathbb{R}^{h \times K}$$

(promedio de losses)

$$\Rightarrow \frac{\partial L}{\partial w_{i,k}}$$

↓
peso del feature i
para la clase k

$$W = \begin{bmatrix} w_{11} & \dots & w_{1K} \\ \vdots & & \vdots \\ w_{h1} & \dots & w_{hK} \end{bmatrix}$$

definimos el error $dZ = \hat{Y} - Y \rightarrow \frac{\partial L}{\partial Z}$

entonces $dW = \frac{1}{h} X^T dZ$ 
 $= \frac{1}{h} X^T (\hat{Y} - Y)$

$$\Rightarrow db = \frac{1}{h} \sum_{i=1}^h dZ_i$$

⑥ Actualización

$$W := W - \alpha dW$$

$$b := b - \alpha db$$

donde α es
el learning rate