

Clasificación de Géneros Musicales Mediante XGBoost: Optimización de Hiperparámetros en un Conjunto de Datos Desbalanceado

Juan Pablo Arteaga Patiño
A01665795

Instituto Tecnológico y de Estudios Superiores de Monterrey

11 de septiembre de 2026

Resumen

En este trabajo se documenta la implementación de un modelo de clasificación multiclase basado en XGBoost para predecir el género musical principal de una canción a partir de un conjunto de atributos numéricos y categóricos extraídos de metadatos de pistas musicales. A diferencia de una implementación manual del algoritmo, en este caso se utilizó un conjunto de datos considerablemente más grande, aprovechando librerías optimizadas de machine learning capaces de entrenar de forma eficiente sobre un mayor volumen de información. Se identificó un fuerte desbalance entre las clases del conjunto de datos, lo cual guió decisiones clave de diseño, entre ellas el uso de f1-macro como métrica objetivo durante la búsqueda de hiperparámetros mediante GridSearchCV. El modelo final alcanzó una exactitud de 89.17% y un f1-macro de 89.19% sobre el conjunto de prueba. Se presentan además un análisis de la matriz de confusión normalizada, la curva ROC one-vs-rest y la curva de aprendizaje del modelo, con el fin de evaluar tanto su desempeño como su capacidad de generalización.

1 Introducción

La clasificación automática de géneros musicales es un problema clásico dentro del área de *music information retrieval*, con aplicaciones directas en sistemas de recomendación, organización de bibliotecas musicales y plataformas de *streaming*. A diferencia de otros problemas de clasificación con clases relativamente balanceadas, la asignación de géneros musicales presenta un reto adicional: las bases de datos reales suelen estar dominadas por unos cuantos géneros populares, mientras que géneros menos comunes cuentan con muy pocos ejemplos para el aprendizaje del modelo.

El presente trabajo forma parte de una segunda etapa de un proyecto más amplio en el que, en una primera fase, se implementó un modelo de regresión multinomial de manera manual (sin uso de *frameworks* de *machine learning*) sobre un conjunto de datos más pequeño. Para esta segunda fase, al contar ya con funciones y herramientas capaces de entrenar modelos de forma más robusta y eficiente, se decidió trabajar con un conjunto de datos considerablemente más grande: un extracto del conjunto de pistas musicales *tracks.csv*, cuyo objetivo es predecir el género principal (`track_genre_top`) de una canción a partir de atributos del álbum, del artista y de la propia pista.

El objetivo de este documento es describir el proceso de preprocesamiento de datos, la metodología utilizada

para el entrenamiento y ajuste de un modelo *XGBoost*, así como el análisis de los resultados obtenidos, prestando especial atención al efecto que tiene el desbalance de clases sobre las métricas de evaluación y sobre el comportamiento del modelo.

2 Conjunto de Datos y Preprocesamiento

2.1 Fuente de datos

El conjunto de datos utilizado corresponde a *FMA: A Dataset for Music Analysis* [7], obtenido a través de su ficha en el UCI Machine Learning Repository [8] y del repositorio oficial `mdeff/fma` en GitHub [9]. En particular, se trabajó con un extracto de metadatos de pistas musicales (*tracks.csv*), el cual contiene información a nivel de álbum, artista y pista individual. De la totalidad de columnas disponibles, se seleccionó un subconjunto de trece atributos considerados relevantes para la tarea de clasificación, los cuales se resumen en el Cuadro 1.

2.2 Limpieza y transformación

El archivo original presenta un encabezado de dos niveles (*multi-index*), por lo que, tras seleccionar las columnas de interés, ambos niveles se concatenaron en un

Origen	Atributo
Álbum	Fecha de lanzamiento
Álbum	Favoritos
Álbum	Número de pistas
Álbum	Tipo de álbum
Álbum	Reproducciones (<i>listens</i>)
Artista	Favoritos
Pista	Tasa de bits (<i>bit rate</i>)
Pista	Fecha de creación
Pista	Duración
Pista	Favoritos
Pista	Interés (<i>interest</i>)
Pista	Número de pista
Pista	Género principal (target)

Cuadro 1: Atributos seleccionados del conjunto de datos de pistas musicales.

único nombre de columna para simplificar su manipulación posterior. Dado que el objetivo del modelo es predecir el género principal de la pista, se eliminaron todos los registros cuyo valor de `genre_top` fuera nulo, ya que estos no aportan información utilizable para el entrenamiento supervisado.

Las columnas de fecha (fecha de lanzamiento del álbum y fecha de creación de la pista) se encontraban originalmente en formato de texto, por lo que se convirtieron a formato de fecha y, posteriormente, a un valor entero (*timestamp*), de forma que pudieran ser utilizadas como variables numéricas por el modelo.

La columna de tipo de álbum, al ser categórica y contener valores nulos, se imputó primero con la categoría *unknown* para no descartar dichos registros, y posteriormente se codificó mediante variables *dummy* (*one-hot encoding*), dado que el número de categorías distintas era reducido. Finalmente, una vez completadas todas las transformaciones, se eliminaron los registros restantes con valores nulos en cualquier columna, obteniendo así un conjunto de datos limpio y completamente numérico, listo para la etapa de modelado.

2.3 Distribución del target y desbalance de clases

Un aspecto central identificado durante el análisis exploratorio es que el conjunto de datos se encuentra fuertemente desbalanceado: la gran mayoría de los registros se concentra en un número reducido de géneros musicales, mientras que otros géneros cuentan con muy pocos ejemplos. La Figura 1 ilustra esta distribución.

Este desbalance, confirmado también por los valores de soporte (*support*) reportados en el conjunto de prueba (Cuadro 4), donde géneros como *Rock*, *Experimental* y *Electronic* concentran miles de observaciones frente a géneros como *Easy Listening*, *Jazz* o *Blues*, que cuentan apenas con decenas, tuvo un impacto directo en




Figura 1: Distribución del target (*track_genre_top*) sobre el conjunto de datos completo.

varias decisiones de diseño del modelo, particularmente en la elección de la métrica de evaluación utilizada para la búsqueda de hiperparámetros, como se detalla en la Sección 3.

3 Metodología

3.1 Selección del modelo

Para esta segunda fase del proyecto se optó por utilizar *XGBoost* (*Extreme Gradient Boosting*), un algoritmo de *ensemble* basado en árboles de decisión potenciados por gradiente (*gradient boosting*). Esta elección se debe a que XGBoost es reconocido por su alto desempeño en problemas de clasificación tabular, su capacidad para capturar relaciones no lineales entre variables y su eficiencia computacional al entrenar sobre conjuntos de datos de mayor tamaño, en comparación con las funciones de descenso de gradiente implementadas manualmente en la primera fase del proyecto.

3.2 Pipeline de preprocesamiento

Con el fin de evitar fugas de información (*data leakage*) entre los conjuntos de entrenamiento y prueba, el preprocesamiento numérico se integró dentro de un *pipeline* de *scikit-learn*. Específicamente, se utilizó un *ColumnTransformer* que aplica un escalamiento estándar (*StandardScaler*) a las variables numéricas, mientras que las variables ya codificadas de forma binaria (las variables *dummy* de tipo de álbum) se dejan sin modificar (*passthrough*). Este *pipeline* se combina posteriormente con el clasificador *XGBoost* en un único objeto entrenable.

3.3 Búsqueda de hiperparámetros

Para optimizar el desempeño del modelo se realizó una búsqueda exhaustiva de hiperparámetros mediante *GridSearchCV* [2], con validación cruzada de 5 particiones (*5-fold cross-validation*). Como referencia prác-

tica complementaria sobre búsqueda en cuadrícula, se incluye el tutorial de Seong [11], cuyo ejemplo utiliza *Random Forest*, a diferencia del clasificador XGBoost empleado en este trabajo. El espacio de búsqueda utilizado se resume en el Cuadro 2.

Hiperparámetro	Valores evaluados
n_estimators	100, 200
max_depth	3, 5, 7
learning_rate	0.05, 0.10
subsample	0.8, 1.0

Cuadro 2: *Espacio de hiperparámetros evaluado en la búsqueda de GridSearchCV.*

Una vez concluida la búsqueda, se seleccionó la combinación de hiperparámetros que maximizó la métrica de validación cruzada, y el modelo asociado a dicha combinación se utilizó como modelo final para su evaluación sobre el conjunto de prueba.

3.4 Métrica de evaluación

Debido al fuerte desbalance de clases descrito en la Sección anterior, la elección de la métrica utilizada tanto para guiar la búsqueda de hiperparámetros como para evaluar el desempeño final del modelo resultó crítica. Se decidió utilizar *f1-macro* en lugar de *accuracy*, *f1-score* estándar o *f1-weighted*. La razón de esta decisión es que el *f1-macro* calcula la métrica *f1* de manera independiente para cada clase y posteriormente promedia los resultados sin ponderar por el número de observaciones de cada una. De esta forma, todos los géneros musicales—independientemente de cuántos ejemplos tengan—contribuyen de manera equitativa a la métrica final.

En contraste, utilizar *f1-weighted* habría otorgado mayor peso a los géneros más representados en el conjunto de datos (como *Rock* o *Experimental*), lo cual podría traducirse en un modelo que optimiza su desempeño principalmente sobre dichas clases mayoritarias, a costa de un aprendizaje deficiente sobre los géneros minoritarios. Al utilizar *f1-macro* como métrica objetivo, se buscó forzar al proceso de optimización de hiperparámetros a favorecer configuraciones capaces de generalizar razonablemente bien sobre *todas* las clases del problema, y no únicamente sobre las más frecuentes.

4 Resultados

4.1 Métricas generales

El modelo final, evaluado sobre el conjunto de prueba (20 % del total de los datos, equivalente a 9,920 observaciones), obtuvo los resultados generales resumidos en el Cuadro 3.

Métrica	Valor
Exactitud (<i>Accuracy</i>)	0.8917
Exactitud Balanceada	0.8526
F1 Macro	0.8919
F1 Weighted	0.8915

Cuadro 3: *Métricas generales del modelo XGBoost sobre el conjunto de prueba.*

Es relevante notar que el valor de *accuracy* (89.17 %) y el de *f1-macro* (89.19 %) resultaron muy cercanos entre sí, lo cual es un indicio favorable de que, a pesar del desbalance del conjunto de datos, el modelo no está simplemente favoreciendo a las clases mayoritarias para inflar su exactitud global, sino que mantiene un desempeño razonablemente consistente entre clases.

4.2 Resultados por clase

El Cuadro 4 presenta el reporte de clasificación completo, con las métricas de precisión, *recall* y *f1-score* para cada uno de los 16 géneros musicales considerados, junto con el número de observaciones de prueba (*support*) correspondiente a cada clase.

Género	Precisión	Recall	F1	Soporte
Blues	0.93	0.57	0.70	23
Classical	0.99	0.95	0.97	237
Country	0.95	0.97	0.96	38
Easy Listening	1.00	0.67	0.80	3
Electronic	0.86	0.89	0.87	1,926
Experimental	0.90	0.91	0.90	2,125
Folk	0.96	0.76	0.85	575
Hip-Hop	0.94	0.86	0.90	689
Instrumental	0.97	0.90	0.94	439
International	0.95	0.91	0.93	261
Jazz	0.96	0.86	0.91	116
Old-Time/Hist.	0.98	0.97	0.98	116
Pop	0.98	0.78	0.87	464
Rock	0.85	0.93	0.89	2,793
Soul-RnB	0.97	0.91	0.94	33
Spoken	0.96	0.80	0.87	82
Macro avg	0.95	0.85	0.89	9,920
Weighted avg	0.90	0.89	0.89	9,920

Cuadro 4: *Reporte de clasificación por género sobre el conjunto de prueba.*

Se observa que las clases con menor *recall* (*Blues*, *Easy Listening*, *Folk*) corresponden, en su mayoría, a géneros minoritarios en el conjunto de datos, lo cual es consistente con la dificultad esperada de aprender patrones robustos a partir de pocos ejemplos. No obstante, resulta notable que la precisión se mantiene relativamente alta incluso para dichas clases minoritarias, lo que sugiere que, cuando el modelo predice estos géneros, tiende a acertar, aunque no logra identificar todos sus casos verdaderos.

4.3 Matriz de confusión

La Figura 2 muestra la matriz de confusión sin normalizar sobre el conjunto de prueba, mientras que la Figura 3 presenta la versión normalizada por fila (es decir, cada fila representa el porcentaje de observaciones reales de una clase que fueron asignadas a cada categoría predicha).




Figura 2: Matriz de confusión (valores absolutos) del modelo XGBoost sobre el conjunto de prueba.




Figura 3: Matriz de confusión normalizada por fila del modelo XGBoost sobre el conjunto de prueba.

Dado que un número reducido de géneros concentra la mayoría de las observaciones, la matriz de confusión sin normalizar tiende a opacar el comportamiento del modelo sobre las clases minoritarias: las celdas correspondientes a los géneros mayoritarios dominan visualmente la escala de color, dificultando apreciar patrones de error en las clases con menos ejemplos. Por esta razón, se optó por analizar principalmente la versión normalizada, la cual permite comparar el comportamiento del modelo entre clases independientemente de su tamaño.

Del análisis de la matriz normalizada se desprenden dos observaciones principales. En primer lugar, el género *Rock* —al ser la clase con mayor número de observaciones— es simultáneamente la que acumula el mayor número de aciertos y, en términos absolutos, el mayor número de errores; sin embargo, una parte relevante de dichos errores corresponde a confusiones con los géneros *Folk* y *Experimental*, lo cual podría explicarse por una similitud en las características acústicas o de metadatos entre estos géneros. En segundo lugar,

se identificó que el género *Soul-RnB* es frecuentemente confundido con *Easy Listening*. Esto podría deberse tanto a una similitud real en las características de ambos géneros, como al hecho de que *Easy Listening* es, por un margen considerable, el género con menor número de observaciones en el conjunto de datos, lo cual limita la capacidad del modelo para aprender un patrón lo suficientemente robusto y distintivo para dicha clase.

4.4 Curva ROC

La Figura 4 presenta las curvas ROC bajo el esquema *one-vs-rest* para cada uno de los 16 géneros musicales, junto con los promedios *micro* y *macro*. Este esquema de evaluación multiclase se describe en el ejemplo de curvas ROC de *scikit-learn* [10].




Figura 4: Curvas ROC *one-vs-rest* por género, con promedios *micro* ($AUC = 0.99$) y *macro* ($AUC = 0.97$).

El área bajo la curva (AUC) promedio *micro* fue de 0.99, mientras que el promedio *macro* fue de 0.97. La cercanía entre ambos valores es, nuevamente, un indicio de que el modelo mantiene un buen poder discriminativo incluso al considerar cada clase de manera individual y sin ponderar por su tamaño. La mayoría de las clases individuales presentan un AUC igual o superior a 0.98, con la notable excepción de *Easy Listening* ($AUC = 0.72$), lo cual es consistente con el bajo número de observaciones de esta clase y con su elevada tasa de confusión con *Soul-RnB* identificada en la matriz de confusión normalizada.

4.5 Curva de aprendizaje

Finalmente, se generó la curva de aprendizaje del modelo, evaluando el *f1-macro* tanto en el conjunto de entrenamiento como en el de validación conforme se incrementa el número de ejemplos utilizados para entrenar (Figura 5). Este procedimiento corresponde al descrito en la documentación de *learning_curve* de *scikit-learn* [4].

Se observa que la métrica de entrenamiento se mantiene consistentemente alta y prácticamente constante (alrededor de 0.97–0.98) a lo largo de todos los tamaños de conjunto evaluados, mientras que la métrica




Figura 5: Curva de aprendizaje del modelo XGBoost (*f1-macro*).

de validación, aunque muestra una tendencia claramente creciente conforme aumenta el número de ejemplos de entrenamiento (pasando de aproximadamente 0.65 con cerca de 8,000 ejemplos a 0.83 con el conjunto completo de entrenamiento), permanece consistentemente por debajo de la métrica de entrenamiento, con una brecha que se reduce pero no llega a cerrarse por completo.

Esta combinación de patrones —un desempeño de entrenamiento alto y estable junto con un desempeño de validación notablemente inferior— es característica de un cierto grado de sobreajuste (*overfitting*): el modelo parece estar ajustándose a particularidades del conjunto de entrenamiento que no siempre se generalizan igual de bien al conjunto de validación. No obstante, la tendencia ascendente y aún no saturada de la curva de validación sugiere que este sobreajuste no es severo, y que el modelo se beneficiaría de contar con más datos de entrenamiento, lo cual muy probablemente continuaría cerrando la brecha entre ambas curvas. Adicionalmente, la aplicación de técnicas de regularización más estrictas (por ejemplo, ajustando los parámetros de regularización L1/L2 de XGBoost, reduciendo la profundidad máxima de los árboles, o incorporando *early stopping* durante el entrenamiento) podría ayudar a mitigar este comportamiento sin sacrificar de forma importante el desempeño general del modelo.

5 Discusión

Los resultados obtenidos permiten concluir que el modelo XGBoost, combinado con una búsqueda de hiperparámetros orientada explícitamente a maximizar el desempeño equilibrado entre clases (*f1-macro*), logra un desempeño sólido sobre un conjunto de datos con un desbalance considerable. La cercanía entre las métri-

cas de *accuracy*, *f1-macro* y *f1-weighted* indica que el modelo no está simplemente memorizando el comportamiento de las clases mayoritarias, sino que logra generalizar razonablemente bien incluso hacia géneros con pocas observaciones, si bien estos últimos siguen presentando los valores más bajos de *recall* y, en el caso particular de *Easy Listening*, del área bajo la curva ROC.

Los patrones de confusión identificados —particularmente entre *Rock*, *Folk* y *Experimental*, así como entre *Soul-RnB* y *Easy Listening*— sugieren que existe una similitud real en las características acústicas o de metadatos entre dichos pares de géneros, lo cual podría explorarse en trabajo futuro mediante un análisis más detallado de las variables más influyentes (*feature importance*) del modelo, o mediante la incorporación de atributos adicionales que permitan discriminar mejor entre estos géneros afines.

6 Conclusiones

En este trabajo se implementó un modelo de clasificación multiclase basado en XGBoost para predecir el género musical de una pista a partir de sus metadatos, sobre un conjunto de datos considerablemente más grande que el utilizado en la implementación manual de la primera fase del proyecto. El fuerte desbalance entre clases identificado en el conjunto de datos guio decisiones metodológicas clave, en particular la elección de *f1-macro* como métrica objetivo tanto para la búsqueda de hiperparámetros como para la evaluación final, con el fin de evitar que el modelo favoreciera desproporcionadamente a los géneros más representados.

El modelo final alcanzó una exactitud de 89.17% y un *f1-macro* de 89.19% sobre el conjunto de prueba, con un desempeño particularmente sólido en géneros bien representados como *Classical*, *Country* y *Old-Time/Historic*, y un desempeño más limitado en géneros minoritarios como *Blues* y *Easy Listening*. El análisis de la curva de aprendizaje reveló un posible sobreajuste moderado, aunque la tendencia creciente y no saturada de la métrica de validación sugiere que este efecto podría mitigarse incrementando el volumen de datos de entrenamiento o aplicando técnicas adicionales de regularización. En conjunto, los resultados confirman la viabilidad de utilizar XGBoost, en conjunto con una búsqueda cuidadosa de hiperparámetros y una métrica de evaluación adecuada al contexto de desbalance de clases, como una herramienta robusta para la clasificación de géneros musicales.

Referencias

- [1] Chen, T., & Guestrin, C. (2016). *XGBoost: A Scalable Tree Boosting System*. Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining.

- [2] Scikit-learn. *GridSearchCV*. https://scikit-learn.org/stable/modules/generated/sklearn.model_selection.GridSearchCV.html
- [3] Scikit-learn. *f1_score*. https://scikit-learn.org/stable/modules/generated/sklearn.metrics.f1_score.html
- [4] Scikit-learn. *Learning Curve*. https://scikit-learn.org/stable/modules/generated/sklearn.model_selection.learning_curve.html
- [5] Scikit-learn. *ROC Curve*. https://scikit-learn.org/stable/modules/generated/sklearn.metrics.roc_curve.html
- [6] XGBoost Developers. *XGBoost Documentation*. <https://xgboost.readthedocs.io/>
- [7] Defferrard, M., Benzi, K., Vanderghelynst, P., & Bresson, X. (2017). *FMA: A Dataset for Music Analysis*. International Society for Music Information Retrieval Conference (ISMIR).
- [8] Defferrard, M., Benzi, K., Vanderghelynst, P., & Bresson, X. (2017). *FMA: A Dataset for Music Analysis* [Conjunto de datos]. UCI Machine Learning Repository. DOI: [10.24432/C5HW28](https://archive.ics.uci.edu/dataset/386/fma+a+dataset+for+music+analysis). <https://archive.ics.uci.edu/dataset/386/fma+a+dataset+for+music+analysis>
- [9] Defferrard, M., y colaboradores. *FMA: A Dataset for Music Analysis* [Repositorio de código y recursos]. GitHub. <https://github.com/mdeff/fma>
- [10] Scikit-learn. *Multiclass Receiver Operating Characteristic (ROC)*. https://scikit-learn.org/stable/auto_examples/model_selection/plot_roc.html
- [11] Seong, S. (2024, 13 de marzo). *Random Forest with Grid Search*. Cloud Villains, Medium. <https://medium.com/cloudvillains/random-forest-with-grid-search-b739fb0da311>